



UNIVERSIDADE FEDERAL DE PERNAMBUCO
CENTRO DE INFORMÁTICA
GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO



Modelagem Preditiva de Visitas Médicas: Um Estudo Baseado em Múltiplos Classificadores

Trabalho de Graduação

Aluno(a): Tomás Nascimento Pimentel Barros (tnpb@cin.ufpe.br)

Orientador(a): Tsang Ing Ren (tir@cin.ufpe.br)

Área: Aprendizagem de Máquina

Dezembro/2024

Resumo

O envelhecimento populacional no Brasil tem gerado maior demanda por serviços médicos, especialmente entre idosos com percepção reduzida de saúde e satisfação de vida. Este trabalho investiga fatores associados à frequência de consultas médicas em adultos com mais de 50 anos, utilizando a base de dados "The National Poll on Healthy Aging"(2017). Diversos algoritmos de classificação, como *Decision Trees*, *Random Forests* e *XGBoost*, serão aplicados e comparados em termos de desempenho e relevância das variáveis. Além disso, o framework META-DES será explorado para analisar sua eficácia em bases de pequeno porte. Os resultados contribuirão para entender os determinantes do uso de serviços médicos e otimizar modelos preditivos.

Introdução

O envelhecimento populacional no Brasil tem se destacado como um fenômeno demográfico acelerado, com o número de idosos ultrapassando o de jovens, conforme dados recentes do (IBGE, 2019) [2]. Essa mudança na estrutura etária implica em uma crescente demanda por serviços de saúde, uma vez que a percepção de saúde geralmente declina com o avanço da idade (IEPS, 2023) [4]. Essa dinâmica se reflete no aumento do uso de serviços médicos por parte da população idosa. Dados do IEPS indicam um crescimento significativo na proporção de idosos que consultaram um médico nos últimos 12 meses, especialmente nas faixas etárias de 60 a 64 anos e acima de 80 anos.

Estudos como o de Smith et al. (2014) [3] sugerem que uma menor satisfação com a vida entre idosos pode estar associada a um aumento no número de visitas médicas. Esse fenômeno pode ser explicado pela maior preocupação com a saúde decorrente da insatisfação pessoal, o que frequentemente leva à busca mais frequente por cuidados médicos. Esse comportamento, por sua vez, aumenta os custos associados ao sistema de saúde, considerando os gastos com consultas, exames e tratamentos.

Diante desse cenário, torna-se essencial investigar como variáveis relacionadas à saúde, aspectos psicossociais e características sociodemográficas influenciam o número de visitas médicas realizadas por idosos. Este trabalho tem como objetivo analisar o conjunto de dados "The National Poll on Healthy Aging" (2017) [5] para identificar variáveis significativas dentre as 13 disponíveis que impactam a frequência de consultas médicas em adultos com mais de 50 anos. Para isso, serão empregados múltiplos classificadores, *Decision Trees*, *Multinomial Logistic Regression*, *Naive Bayes*, *k-Nearest Neighbors*, *Support Vector Machines*, *Neural Networks*, *Random Forests*, *Gradient Tree Boosting*, *XGBoost*, *CatBoost*, *LightGBM*, decorrente da metodologia utilizada em Mostafa Rezapour et al. (2022) [3]. Além disso, será comparado o desempenho desses classificadores utilizando a metodologia do META-DES (2015) [1], reconhecida por sua eficácia em bases de dados pequenas. O estudo também investigará quais variáveis são mais relevantes para os modelos e avaliará o desempenho do melhor classificador em cada abordagem.

Objetivos

O objetivo geral deste trabalho é avaliar e comparar a eficácia de diferentes classificadores em prever a frequência de consultas médicas ao longo de um ano para indivíduos com mais de 50 anos, utilizando a base de dados "The National Poll on Healthy Aging (2017)"[5]. Além disso, busca-se identificar as variáveis mais relevantes para essa previsão e explorar a eficácia de abordagens baseadas no framework META-DES (2015) [1] especialmente em bases de dados com número limitado de instâncias.

São objetivos específicos do projeto:

1. Analisar o desempenho de diferentes classificadores, como *Decision Trees*, *Multinomial Logistic Regression*, *Naive Bayes*, *k-Nearest Neighbors*, *Support Vector Machines*, *Neural Networks*, *Random Forests*, *Gradient Tree Boosting*, *XGBoost*, *CatBoost*, *LightGBM*, na tarefa de previsão da variável alvo.
2. Comparar a capacidade dos classificadores em identificar as variáveis mais importantes para a previsão da frequência de consultas médicas.
3. Avaliar o desempenho do framework META-DES no problema, identificando as variáveis mais relevantes e comparando os resultados obtidos pelo melhor classificador dessa abordagem com o melhor classificador tradicional.
4. Realizar uma análise comparativa entre os melhores resultados obtidos pelos classificadores tradicionais e os baseados no framework META-DES.

Metodologia

1. Revisão da Literatura

Será realizada uma revisão abrangente sobre os algoritmos de classificação selecionados e suas aplicações em dados de saúde, especialmente em bases com número limitado de instâncias. Também serão investigadas metodologias para comparação de classificadores e extração de variáveis importantes.

2. Preparação dos Dados

A base de dados "The National Poll on Healthy Aging"(2017) [5] será analisada para identificar possíveis inconsistências, valores ausentes ou outliers. Caso necessário, serão aplicados tratamentos de limpeza e pré-processamento, como normalização e codificação de variáveis categóricas.

3. Desenvolvimento dos Modelos de Classificação

Serão implementados e treinados os seguintes algoritmos de classificação: *Decision Trees*, *Multinomial Logistic Regression*, *Naive Bayes*, *k-Nearest Neighbors*, *Support Vector Machines*, *Neural Networks*, *Random Forests*, *Gradient Tree Boosting*, *XGBoost*, *CatBoost*, *LightGBM*. A avaliação dos modelos será baseada em métricas como acurácia, precisão, recall e F1-score, utilizando validação cruzada para assegurar a robustez dos resultados.

4. Aplicação do Framework META-DES

O framework META-DES será utilizado para identificar as variáveis mais relevantes e avaliar o desempenho dos classificadores em comparação com os modelos tradicionais. Essa abordagem é particularmente útil para bases com poucas instâncias, como a utilizada neste estudo.

5. Análise Comparativa

Os resultados obtidos pelos classificadores tradicionais e pelo framework META-DES serão comparados para identificar o modelo com melhor desempenho. Além disso, será feita uma análise das variáveis consideradas mais importantes por cada abordagem, avaliando a consistência e relevância dessas variáveis.

Cronograma

	Dezembro		Janeiro		Fevereiro		Março	
Definição do escopo e elaboração da proposta	X	X						
Revisão de literatura		X	X	X	X			
Estudo da base e Possíveis Tratamentos			X	X				
Desenvolvimento das Metodologias de Classificação e Comparação			X	X	X			
Implementação de melhorias			X	X	X			
Avaliação dos resultados					X	X		
Escrita do trabalho e elaboração da apresentação					X	X	X	X

Referências

- [1] Rafael M.O. Cruz, Robert Sabourin, George D.C. Cavalcanti, and Tsang Ing Ren. Meta-des: A dynamic ensemble selection framework using meta-learning. *Pattern Recognition*, 48(5):1925–1935, May 2015.
- [2] Governo Federal. Instituto brasileiro de geografia e estatística, 2019. url :<https://www.ibge.gov.br/> [Acessado em: (2024)].
- [3] Eric S. Kim, Nansook Park, Jennifer K. Sun, Jacqui Smith, and Christopher Peterson. Life satisfaction and frequency of doctor visits. *Psychosomatic Medicine*, 76(1):86–93, Jan 2014.
- [4] Karla Giacomini Matías Mrejen, Leticia Nunes. Envelhecimento populacional e saúde dos idosos: O brasil está preparado? *Estudo Institucional EPS*10, 2023.
- [5] NPHA. National Poll on Healthy Aging (NPHA), [United States], April 2017 (ICPSR 37305). UCI Machine Learning Repository, 2017. DOI: <https://doi.org/10.3886/ICPSR37305.v1>.

Possíveis Avaliadores(as)

- Leandro Maciel Almeida (lma3@cin.ufpe.br)
- Cleber Zanchetin (cz@cin.ufpe.br)